Ethische Grundlagen der KI-Regulierung am Beispiel der KI-Grundverordnung

Bettina Berendt

TU Berlin, Weizenbaum-Institut und KU Leuven

Europarechtstage Würzburg 8./9.11.2024

Slides unter www.berendt.de/bettina

Ziele

EG (1): Zweck dieser Verordnung ist es,

das Funktionieren des Binnenmarkts zu verbessern, indem ein einheitlicher Rechtsrahmen … im Einklang mit den Werten der Union festgelegt wird …,

um die Einführung von menschenzentrierter und vertrauenswürdiger künstlicher Intelligenz (KI) zu fördern

und gleichzeitig ein hohes Schutzniveau in Bezug auf Gesundheit, Sicherheit und der in der Charta der Grundrechte der Europäischen Union („Charta“) verankerten Grundrechte, einschließlich Demokratie, Rechtsstaatlichkeit und Umweltschutz, sicherzustellen,

den Schutz vor schädlichen Auswirkungen von KI-Systemen in der Union zu gewährleisten

und gleichzeitig die Innovation zu unterstützen.

Primär ökonomisch?!

“Ethisch” in einer in der “KI-Ethik” häufigen Begriffsverwendung

Ökonomisch, ethisch, etwas 3.?

Ethik als Reflektion 101: Fragen und normative Begründung

Woraus begründet sich ein Aspekt der Regulierung?	Auf welche normativen Ethik rekurriert dies primär?
Wer überhaupt als moralisch Handelnder und/oder als moralisch Behandelter "zählt"	Grundlagen der Modellierung ethischen Handelns
Welche Folgen die zu regulierenden Aktivitäten haben (können)	Konsequentialistische Ethik
Welche Rechte die moralisch Behandelten haben	Deontologische Ethik
Welche Verantwortungen und Verpflichtungen die moralisch Handelnden haben	
In welchen Interdependenzen Aufmerksamkeit, Aufeinander-Eingehen und Verantwortung gelebt werden	Care-Ethik
Welche Dispositionen moralisch Handelnde haben sollten (und wie man diese erlernen kann)	Tugendethik
Was man schon über die zu regulierenden Aktivitäten weiß	Berufsethische Verpflichtungen: Wissen über die eigene Tätigkeit, ihre Folgen, Grenzen und seine eigenen Grenzen; Aufklärung der Öffentlichkeit
Was man schon über die Effekte von Maßnahmen weiß / zu glauben weiß	

Agenda

Entsprechende ethische Grundlagen in der KI-VO?	Auf welche normativen Ethik rekurriert dies primär?
Beschreibung: • Grundlagen • Folgen • Prinzipien und Regeln	Grundlagen der Modellierung ethischen Handelns
	Konsequentialistische Ethik
	Deontologische Ethik
Zweifel: Care	Care-Ethik
Kritik: Wissen	Tugendethik
	Berufsethische Verpflichtungen: Wissen über die eigene Tätigkeit, ihre Folgen, Grenzen und seine eigenen Grenzen; Aufklärung der Öffentlichkeit

Geschichte und Kontext (Auswahl)

1980er+: Regulierung “automatisierter Entscheidungen”
(Artikel 15 Datenschutzrichtlinie und Artikel 22 DSGVO)

2016: IEEE Ethically Aligned Design – Version One Request for Input
(2019 veröffentlicht)

04/2019: EU Guidelines on Trustworthy AI

10/2019: Gutachten der Datenethikkommission

02/2020: EU Whitepaper on AI

04/2020: AlgorithmWatch Datenbank von 167 KI-Ethik-Guidelines
(https://inventory.algorithmwatch.org/)

04/2021: Vorstellung KI-VO durch EU-Kommission

11/2021: UNESCO Recommendation on the Ethics of Artificial Intelligence

2022: *Large language models* kommen auf den allgemeinen Markt

11/2022: DSA tritt in Kraft

11/2023: Erster globaler AI Safety Summit @ Bletchley Park

08/2024: KI-VO tritt in Kraft

Verstärkt seit ca. 2020: vielfältige Regulierungsinitiativen weltweit
(https://www.whitecase.com/insight-our-thinking/ai-watch-global-regulatory-tracker)

Grundlagen

Wessen Aktivitäten werden (nicht) reguliert? Moralisch Handelnde und Moralisch Behandelte

Moralisch Handelnde: Artikel 3.

- „Anbieter“ eine natürliche oder juristische Person, Behörde, Einrichtung oder sonstige Stelle, die ein KI-System oder ein KI-Modell mit allgemeinem Verwendungszweck entwickelt oder entwickeln lässt und es unter ihrem eigenen Namen oder ihrer Handelsmarke in Verkehr bringt oder das KI-System unter ihrem eigenen Namen oder ihrer Handelsmarke in Betrieb nimmt, sei es entgeltlich oder unentgeltlich;
- „Betreiber“ eine natürliche oder juristische Person, Behörde, Einrichtung oder sonstige Stelle, die ein KI-System in eigener Verantwortung verwendet, es sei denn, das KI-System wird im Rahmen einer persönlichen und nicht beruflichen Tätigkeit verwendet;
- „Bevollmächtigter“ eine in der Union ansässige oder niedergelassene natürliche oder juristische Person, die vom Anbieter eines KI-Systems oder eines KI-Modells mit allgemeinem Verwendungszweck schriftlich dazu bevollmächtigt wurde und sich damit einverstanden erklärt hat, in seinem Namen die in dieser Verordnung festgelegten Pflichten zu erfüllen bzw. Verfahren durchzuführen;
- „Einführer“ eine in der Union ansässige oder niedergelassene natürliche oder juristische Person, die ein KI-System, das den Namen oder die Handelsmarke einer in einem Drittland niedergelassenen natürlichen oder juristischen Person trägt, in Verkehr bringt;
- „Händler“ eine natürliche oder juristische Person in der Lieferkette, die ein KI-System auf dem Unionsmarkt bereitstellt, mit Ausnahme des Anbieters oder des Einführers;
- „Akteur“ einen Anbieter, Produkthersteller, Betreiber, Bevollmächtigten, Einführer oder Händler;

Moralisch Behandelte: (EG 2): natürliche Personen, Unternehmen, Demokratie und Rechtsstaatlichkeit sowie die Umwelt

Folgen

Risikobasierter Ansatz

- (25) Diese Verordnung sollte die Innovation fördern
- (26) Um ein verhältnismäßiges und wirksames verbindliches Regelwerk für KI-Systeme einzuführen, sollte ein klar definierter risikobasierter Ansatz verfolgt werden. Bei diesem Ansatz sollten Art und Inhalt solcher Vorschriften auf die Intensität und den Umfang der Risiken zugeschnitten werden, die von KI-Systemen ausgehen können. Es ist daher notwendig, bestimmte inakzeptable Praktiken im Bereich der KI zu verbieten und Anforderungen an Hochrisiko-KI-Systeme und Pflichten für die betreffenden Akteure sowie Transparenzpflichten für bestimmte KI-Systeme festzulegen.

- Hier wird abgewogen:
  - Compliance-Kosten/Aufwand/mögliches Innovationshemmnis als negative Folge für KI-Produzenten (usw.) als moralische Handelnde
  - Risiko (negative Technikfolge/Schaden mit Auftretenswahrscheinlichkeit) bzw. Risikoabminderung (positive Folge der Regulierung für moralisch Behandelte)
- Gesetz sieht explizit keine Abwägung Nutzen-Risiko vor, obwohl das Spannungsverhältnis (Binnenmarkt/Innovation) *gut* ←→ Risiken *schlecht* immer präsent ist.

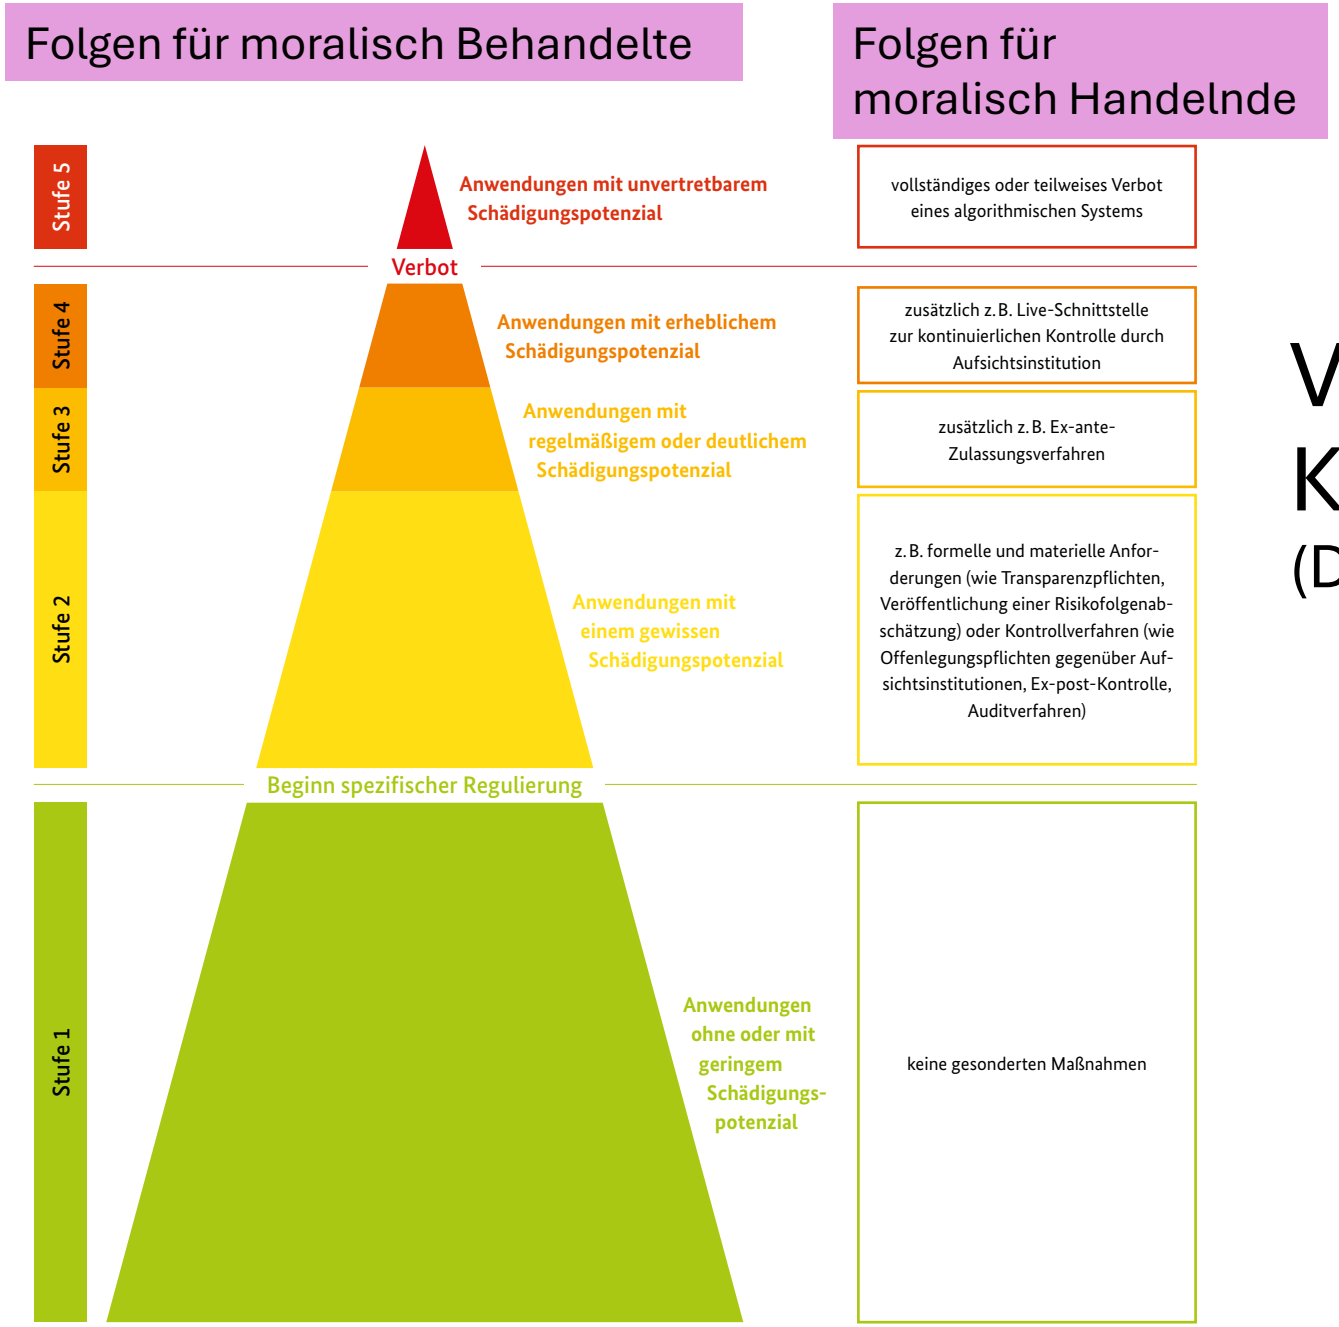

Vorbild Kritikalitätspyramide

(Datenethikkommission, 2019)

Aber wie wird das Risiko bestimmt?

- Durch Proxy Anwendungsdomäne (Bildung, Arbeit, …)
- V.a. mittels Selbsteinschätzung der moralisch Handelnden
- KI-Modelle mit allgemeinem Verwendungszweck
  - Aufgrund Proxy-Maß “Größe”
  - Vage und Bewertungen in die Zukunft verlegend
  - Ohne erkennbare Einbeziehung der moralische Behandelten
  - Keine klaren Pflichten entlang der KI-Wertschöpfungskette

(Helberger et al., 2023)

Prinzipien und Regeln

Prinzipien der HLEG: Ethikleitlinien für vertrauenswürdige KI (2019)

– wie referiert in EG (27)

- sieben unverbindliche ethische Grundsätze für KI entwickelt, die dazu beitragen sollten, dass KI vertrauenswürdig und ethisch vertretbar ist.
- …
- Die Anwendung dieser Grundsätze sollte, soweit möglich, in die Gestaltung und Verwendung von KI-Modellen einfließen.
- Sie sollten in jedem Fall als Grundlage für die Ausarbeitung von Verhaltenskodizes im Rahmen dieser Verordnung dienen.
- Alle Interessenträger, einschließlich der Industrie, der Wissenschaft, der Zivilgesellschaft und der Normungsorganisationen, werden aufgefordert, die ethischen Grundsätze bei der Entwicklung freiwilliger bewährter Verfahren und Normen, soweit angebracht, zu berücksichtigen.

HLEG-Prinzipien: im Einzelnen

1-6 wie referiert in EG (27), 7 aus HLEG (2019)

- **„menschliches Handeln und menschliche Aufsicht“** [bedeutet], dass ein KI-System entwickelt und als Instrument verwendet wird, das den Menschen dient, die Menschenwürde und die persönliche Autonomie achtet und so funktioniert, dass es von Menschen angemessen kontrolliert und überwacht werden kann.
- **„Technische Robustheit und Sicherheit“** bedeutet, dass KI-Systeme so entwickelt und verwendet werden, dass sie im Fall von Schwierigkeiten robust sind und widerstandsfähig gegen Versuche, die Verwendung oder Leistung des KI-Systems so zu verändern, dass dadurch die unrechtmäßige Verwendung durch Dritte ermöglicht wird, und dass ferner unbeabsichtigte Schäden minimiert werden.
- **„Privatsphäre und Daten-Governance“** bedeutet, dass KI-Systeme im Einklang mit den geltenden Vorschriften zum Schutz der Privatsphäre und zum Datenschutz entwickelt und verwendet werden und dabei Daten verarbeiten, die hohen Qualitäts- und Integritätsstandards genügen.
- **„Transparenz“** bedeutet, dass KI-Systeme so entwickelt und verwendet werden, dass sie angemessen nachvollziehbar und erklärbar sind, wobei den Menschen bewusst gemacht werden muss, dass sie mit einem KI-System kommunizieren oder interagieren, und dass die Betreiber ordnungsgemäß über die Fähigkeiten und Grenzen des KI-Systems informieren und die betroffenen Personen über ihre Rechte in Kenntnis setzen müssen.
- **„Vielfalt, Nichtdiskriminierung und Fairness“** bedeutet, dass KI-Systeme in einer Weise entwickelt und verwendet werden, die unterschiedliche Akteure einbezieht und den gleichberechtigten Zugang, die Geschlechtergleichstellung und die kulturelle Vielfalt fördert, wobei diskriminierende Auswirkungen und unfaire Verzerrungen, die nach Unionsrecht oder nationalem Recht verboten sind, verhindert werden.
- **„Soziales und ökologisches Wohlergehen“** bedeutet, dass KI-Systeme in nachhaltiger und umweltfreundlicher Weise und zum Nutzen aller Menschen entwickelt und verwendet werden, wobei die langfristigen Auswirkungen auf den Einzelnen, die Gesellschaft und die Demokratie überwacht und bewertet werden.
- **Rechenschaftspflicht** (“Accountability”): Including auditability, minimisation and reporting of negative impact, trade-offs and redress.

HLEG-Prinzipien: (m)eine informatisch inspirierte Kategorisierung

ethisches Ziel / allgemeine Systemeigenschaft / allgemeine Maßnahme

- **„menschliches Handeln und menschliche Aufsicht“** [bedeutet], dass ein KI-System entwickelt und als Instrument verwendet wird, das den Menschen dient, die Menschenwürde und die persönliche Autonomie achtet und so funktioniert, dass es von Menschen angemessen kontrolliert und überwacht werden kann.
- **„Technische Robustheit und Sicherheit“** bedeutet, dass KI-Systeme so entwickelt und verwendet werden, dass sie im Fall von Schwierigkeiten robust sind und widerstandsfähig gegen Versuche, die Verwendung oder Leistung des KI-Systems so zu verändern, dass dadurch die unrechtmäßige Verwendung durch Dritte ermöglicht wird, und dass ferner unbeabsichtigte Schäden minimiert werden.
- **„Privatsphäre und Daten-Governance“** bedeutet, dass KI-Systeme im Einklang mit den geltenden Vorschriften zum Schutz der Privatsphäre und zum Datenschutz entwickelt und verwendet werden und dabei Daten verarbeiten, die hohen Qualitäts- und Integritätsstandards genügen.
- **„Transparenz“** bedeutet, dass KI-Systeme so entwickelt und verwendet werden, dass sie angemessen nachvollziehbar und erklärbar sind, wobei den Menschen bewusst gemacht werden muss, dass sie mit einem KI-System kommunizieren oder interagieren, und dass die Betreiber ordnungsgemäß über die Fähigkeiten und Grenzen des KI-Systems informieren und die betroffenen Personen über ihre Rechte in Kenntnis setzen müssen.
- **„Vielfalt, Nichtdiskriminierung und Fairness“** bedeutet, dass KI-Systeme in einer Weise entwickelt und verwendet werden, die unterschiedliche Akteure einbezieht und den gleichberechtigten Zugang, die Geschlechtergleichstellung und die kulturelle Vielfalt fördert, wobei diskriminierende Auswirkungen und unfaire Verzerrungen, die nach Unionsrecht oder nationalem Recht verboten sind, verhindert werden.
- **„Soziales und ökologisches Wohlergehen“** bedeutet, dass KI-Systeme in nachhaltiger und umweltfreundlicher Weise und zum Nutzen aller Menschen entwickelt und verwendet werden, wobei die langfristigen Auswirkungen auf den Einzelnen, die Gesellschaft und die Demokratie überwacht und bewertet werden.
- **Rechenschaftspflicht** (“Accountability”): Including auditability, minimisation and reporting of negative impact, trade-offs and redress.

Von Zielen zu spezifischen Systemeigenschaften und Maßnahmen

(ggf. nur für bestimmte Risikoklassen: verboten / HR / R / NR)

Prinzip	Umsetzung (Auswahl)
1a. menschliches Handeln (Respektierung von Menschenwürde und Autonomie)	Verbot bestimmter KI-Systeme (z.B. social scoring, bestimmte Überwachungstechniken, trügerische Techniken) (Kapitel II)
1b. menschliche Aufsicht	Artikel 14 Menschliche Aufsicht (HR)
2. Technische Robustheit und Sicherheit	Artikel 9 Risikomanagementsystem (HR), Artikel 15 Genauigkeit, Robustheit und Cybersicherheit (HR)
3. Privatsphäre und Daten-Governance	EG 9, 69, Artikel 27 (HR), Artikel 10 Daten und Daten-Governance (HR)
6. Soziales und ökologisches Wohlergehen	Artikel 95 (freiwillige) Verhaltenskodices: Beurteilung und Minimierung der Auswirkungen von KI-Systemen auf die ökologische Nachhaltigkeit
7. Rechenschaftspflicht	Durchgehende Dokumentationspflichten, z.B. Artikel 11-13 (HR), Artikel 17 Qualitätsmanagementsystem (HR) und ff.; allerdings verwässert

Von Zielen zu spezifischen Systemeigenschaften und Maßnahmen

(ggf. nur für bestimmte Risikoklassen: verboten / HR / R / NR)

Prinzip	Umsetzung (Auswahl)
4. Transparenz	Artikel13 Transparenz und Bereitstellung von Informationen für die Betreiber (HR); Artikel 50 Transparenzpflichten für Anbieter und Betreiber bestimmter KI-Systeme: Informieren, dass Nutzer mit einem KI-System interagiert / dass Inhalte von einem KI-System erzeugt wurden, etc. (R)
5. Vielfalt, Nichtdiskriminierung und Fairness	Artikel 9 Risikomanagementsystem (HR); Artikel 10 Folgenabschätzung (HR); Anhang IV Technische Dokumentation

Care?

Wortlaut vs. Prozess?

- Verboten: [jedes] KI-System, das eine Vulnerabilität oder Schutzbedürftigkeit einer natürlichen Person oder einer bestimmten Gruppe von Personen aufgrund ihres Alters, einer Behinderung oder einer bestimmten sozialen oder wirtschaftlichen Situation mit dem Ziel oder der Wirkung ausnutzt, das Verhalten dieser Person oder einer dieser Gruppe angehörenden Person in einer Weise wesentlich zu verändern, die dieser Person oder einer anderen Person erheblichen Schaden zufügt oder mit hinreichender Wahrscheinlichkeit zufügen wird; (Artikel 5 (1) b).
- Z.B. EG 60: KI-Systeme, die in den Bereichen Migration, Asyl und Grenzkontrolle eingesetzt werden, betreffen Personen, die sich häufig in einer besonders prekären Lage befinden und vom Ergebnis der Maßnahmen der zuständigen Behörden abhängig sind. … Daher ist es angezeigt, [solche] KI-Systeme … als hochriskant einzustufen (Letzteres geschieht in Form von Anhang III Nr. 7)
- Aber:
  - Wurden diese Personengruppen gehört?
  - “But this narrowing [of time] can also be a matter of ending reflection and adjustment based on patiently waiting for outcomes and on listening … directly counter to an ethics of care … where attentiveness and responsibility are emphasised.” (Anderson, 2022)
  - Speziell zu Migration, Asyl und Grenzkontrolle: …

Anmerkung: Der Kreis der moralisch Behandelten

accessnow.org/press-release/joint-statement-ai-act-fails-migrants-and-people-on-the-move/#skip-to-content

accessnow

NEWS & UPDATES TAKE ACTION OUR WORK GET HELP

Joint statement – A dangerous precedent: how the EU AI Act fails migrants and people on the move

PUBLISHED: 13 MARCH 2024 LAST UPDATED: 13 MARCH 2024

The following statement has been written collectively by the #ProtectNotSurveil coalition following the European Parliament's final vote on the EU AI Act.

On 13 March 2024, the EU Artificial Intelligence Act (AI Act) was adopted by the European Parliament. Whilst the legislation is widely celebrated as a world-first, the EU AI Act falls short in the vital area of migration, failing to prevent harm and provide protection for people on the move.

In its final version, the EU AI Act sets a dangerous precedent. The legislation develops a separate legal framework for the use of AI by law enforcement, migration control and national security authorities, provides unjustified loopholes and even encourages the use of dangerous systems for discriminatory surveillance on the most marginalised in society. This statement outlines the main gaps in protection with respect to AI in

Wissen

Was in der KI-VO eingebunden ist (Bsp.)

Datenschutz als wichtiger “Alliierter”

- Viele ethische Fragen der KI entstehen aus der Verarbeitung personengebundener Daten (z.B. EG 57)
- Datenschutz und Datenschutz-Prinzipien gelten immer auch (z.B. EG 9, 69)
- Datenschutz-Maßnahmen sind komplementär (Artikel 27)
- Datenschutz kann eingeschränkt werden im Interesse anderer Ziele (Nicht-Diskriminierung, Artikel 10 (5))

Wissen

Was in der KI-VO nicht hinreichend eingebunden wird

Was kann man noch aus dem Datenschutz lernen?

- Transparenz ist ein wichtiges Prinzip:
  - “Sunlight is the best disinfectant” (nach Brandeis 1913)
  - „Mit dem Recht auf informationelle Selbstbestimmung wären eine Gesellschaftsordnung und eine diese ermöglichende Rechtsordnung nicht vereinbar, in der Bürger nicht mehr **wissen** können, wer was wann und bei welcher Gelegenheit über sie weiß.“ (BVerfG, Volkszählungsurteil 1983)
- … aber nicht das einzige:
  - „Das Grundrecht gewährleistet insoweit die Befugnis des Einzelnen, grundsätzlich selbst über die Preisgabe und Verwendung seiner persönlichen Daten zu **bestimmen**.“ (ibid.)
- Auf Basis langjähriger Evidenz und Wissenschaft – die DSGVO enthält weitere, datenverarbeitungs-spezifische Prinzipien! (Artikel 5 u.a.)

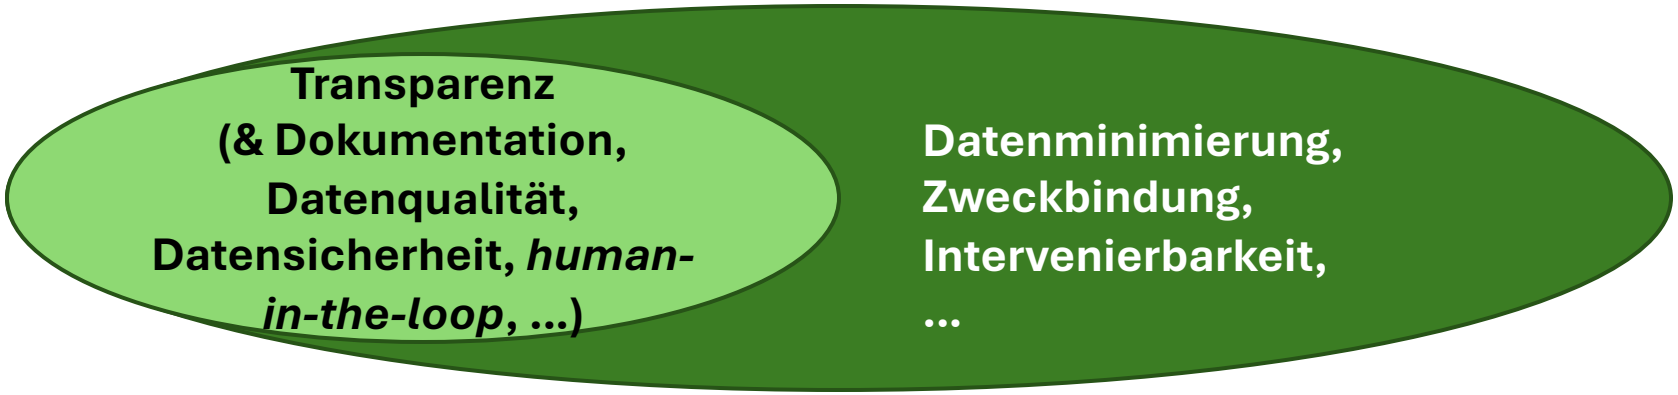

Grenzen der Transparenz (1): Zu enger Blick auf Systeme und ihre Dynamik

- Transparenz (Systemeigenschaft) =/= Erklärung (Kommunikation) =/= Verständnis (Meinung oder Zustand des/der Betroffenen) [1)]
- Zweifelhafter Wert bei schon eingetretenem (und irreversiblem) Schaden [1)]
- Transparenz =/= Akzeptabilität, Intervenierbarkeit, Änderbarkeit: Informations- und Machtasymmetrien [3)] [2)]
- Feedback-Loops, v.a. in größeren soziotechnischen Systemen: *Cumulative causation / runaway feedback loops* [4)] [5)] [2)]

([1)] Edwards & Veale, 2017; [2)] Berendt, 2022; [3)] D'Ignazio & Klein, 2020; [4)] Myrdal, 1944; [5)] Ensign et al., 2018)

https://www.vice.com/en/article/man-dies-by-suicide-after-talking-with-ai-chatbot-widow-says/
https://www.bbc.com/news/technology-67012224
https://www.nytimes.com/2024/10/23/technology/characterai-lawsuit-teen-suicide.html

Grenzen der Transparenz 2: (nicht nur bei Generative AI)

Psychologische Effekte trotz Markierung als KI und Einwilligung

The New York Times

THE SHIFT

Can A.I. Be Blamed for a Teen's Suicide?

The mother of a 14-year-old Florida boy says he became obsessed with a chatbot on Character.AI before his death.

(Berendt, 2025)

Grenzen der ”menschlichen Aufsicht”: Bewusstsein allein reicht nicht *)

Artikel 14: Menschliche Aufsicht

(1) Hochrisiko-KI-Systeme werden so konzipiert und entwickelt, dass sie während der Dauer ihrer Verwendung … von natürlichen Personen wirksam beaufsichtigt werden können.

(4) Für die Zwecke der Durchführung der Absätze 1, 2 und 3 wird das Hochrisiko-KI-System dem Betreiber so zur Verfügung gestellt, dass die natürlichen Personen, denen die menschliche Aufsicht übertragen wurde, angemessen und verhältnismäßig in der Lage sind,

a) die einschlägigen Fähigkeiten und Grenzen des Hochrisiko-KI-Systems angemessen zu verstehen und seinen Betrieb ordnungsgemäß zu überwachen, … ;

b) sich einer möglichen Neigung zu einem automatischen oder übermäßigen Vertrauen in die von einem Hochrisiko-KI-System hervorgebrachte Ausgabe („Automatisierungsbias“) bewusst zu bleiben, insbesondere wenn Hochrisiko-KI-Systeme Informationen oder Empfehlungen ausgeben, auf deren Grundlage natürliche Personen Entscheidungen treffen;

c) die Ausgabe des Hochrisiko-KI-Systems richtig zu interpretieren, … ;

d) in einer bestimmten Situation zu beschließen, das Hochrisiko-KI-System nicht zu verwenden oder die Ausgabe des Hochrisiko-KI-Systems außer Acht zu lassen, außer Kraft zu setzen oder rückgängig zu machen;

e) in den Betrieb des Hochrisiko-KI-Systems einzugreifen oder den Systembetrieb mit einer „Stopptaste“ oder einem ähnlichen Verfahren zu unterbrechen, was dem System ermöglicht, in einem sicheren Zustand zum Stillstand zu kommen.

(*) Ruschemeier, 2023)

Wissen

Wo es in der KI-VO nicht hinreichend eingebunden wird – und die Konstruktion der “ethischen Grundlagen” fragwürdig wird

HLEG-Prinzipien: (m)eine informatisch inspirierte Kategorisierung

ethisches Ziel / allg. Systemeigenschaft / allg. Maßnahme

Diese Kategorienmischung sorgt für viel Verwirrung und übertriebene Claims. So ist z.B. ein transparentes System nicht per se verstehbar.

- **„menschliches Handeln und menschliche Aufsicht“** [bedeutet], dass ein KI-Syste den Menschen dient, die Menschenwürde und die persönliche Autonomie achtet und kontrolliert und überwacht werden kann.
- **„Technische Robustheit und Sicherheit“** bedeutet, dass KI-Systeme so entwickelt u Schwierigkeiten robust sind und widerstandsfähig gegen Versuche, die Verwendung oder dadurch die unrechtmäßige Verwendung durch Dritte ermöglicht wird, und dass ferner unbeab
- **„Privatsphäre und Daten-Governance“** bedeutet, dass KI-Systeme im Einklang mit den gelte chriften zum Schutz der Privatsphäre und zum Datenschutz entwickelt und verwendet werden und dabei Daten verarbe die hohen Qualitäts- und Integritätsstandards genügen.
- **„Transparenz“** bedeutet, dass KI-Systeme so entwickelt und verwendet werden, dass sie angemessen nachvollziehbar und erklärbar sind, wobei den Menschen bewusst gemacht werden muss, dass sie mit einem KI-System kommunizieren oder interagieren, und dass die Betreiber ordnungsgemäß über die Fähigkeiten und Grenzen des KI-Systems informieren und die betroffenen Personen über ihre Rechte in Kenntnis setzen müssen.
- **„Vielfalt, Nichtdiskriminierung und Fairness“** bedeutet, dass KI-Systeme in einer Weise entwickelt und verwendet werden, die unterschiedliche Akteure einbezieht und den gleichberechtigten Zugang, die Geschlechtergleichstellung und die kulturelle Vielfalt fördert, wobei diskriminierende Auswirkungen und unfaire Verzerrungen, die nach Unionsrecht oder nationalem Recht verboten sind, verhindert werden.
- **„Soziales und ökologisches Wohlergehen“** bedeutet, dass KI-Systeme in nachhaltiger und umweltfreundlicher Weise und zum Nutzen aller Menschen entwickelt und verwendet werden, wobei die langfristigen Auswirkungen auf den Einzelnen, die Gesellschaft und die Demokratie überwacht und bewertet werden.
- **Rechenschaftspflicht** (“Accountability”): Including auditability, minimisation and reporting of negative impact, trade-offs and redress.

Wieso eigentlich gerade diese 7 “ethischen Prinzipien”?

Wieso nicht z.B. Prinzipien zur Aufrechterhaltung von Werten und Rechten im Zusammenhang mit:

- der Strukturveränderung des Arbeitsmarktes,
- der Ausweitung ausbeuterischer Lieferketten bei der Datenerhebung und -auswertung, insbesondere im globalen Süden,
- der einseitigen Macht- und Produktivitätssteigerung weniger Firmen,
- der Ausweitung personalisierter Überwachung,
- der unendlichen Welle von KI-generiertem Spam und Betrug,
- der automatisierten Aneignung und Kommerzialisierung von Online-Kulturwerken,
- der Herausbildung globaler Abhängigkeiten durch Oligopoltendenzen in der Industrie,
- der Implikationen militärischer KI-Nutzung,
- den Zusammenhängen zwischen Klimakrise, Migration, Energieverbrauch durch KI-Systeme und KI in Grenzkontroll-, Asyl- und Migrationsbereichen

[1-8, allerdings in einem etwas anderen Zusammenhang: Rehak, 2023]

Drei problematische Feedback-Loops des Prozesses der “ethischen Grundlagen” der KI-VO

1. Die 7 sind Themen, für die IT-Forschung und Industrie “Lösungen” haben
   - Dann nimmt man sie auch eher als “Probleme” wahr

     vgl. die in der NeurIPS-broader-impact-statements-Umfrage am häufigsten genannten *ethical issues* (Ashurst et al., 2022)

Drei problematische Feedback-Loops des Prozesses der “ethischen Grundlagen” der KI-VO

1. Die 7 sind Themen, für die IT-Forschung und Industrie “Lösungen” haben
   - Dann nimmt man sie auch eher als “Probleme” wahr

     vgl. die in der NeurIPS-broader-impact-statements-Umfrage am häufigsten genannten *ethical issues* (Ashurst et al., 2022)
2. Der in der KI-VO betonte Prozess der Öffentlichkeitsbeteiligung (*Open Consultation)*
   - wird als Schaffung einer ‘demokratischen’, geschlossene Feedback-Loop Ethik → Recht → Ethik beschrieben
   - war aber gekennzeichnet durch große Wissens-, Ressourcen- und Macht-Asymmetrien zugunsten großer industrieller Stakeholder ←→ ethischer Diskurs
   - fördert vielmehr maximal eine spezifische Art von Ethik (z.B. die der Industrie: Chance der Selbstregulierung)

(Punkte 2 und 3: Anderson, 2022)

Drei problematische Feedback-Loops des Prozesses der “ethischen Grundlagen” der KI-VO

1. Die 7 sind Themen, für die IT-Forschung und Industrie “Lösungen” haben
   - Dann nimmt man sie auch eher als “Probleme” wahr

     vgl. die in der NeurIPS-broader-impact-statements-Umfrage am häufigsten genannten *ethical issues* (Ashurst et al., 2022)
2. Der in der KI-VO betonte Prozess der Öffentlichkeitsbeteiligung (*Open Consultation)*
   - wird als Schaffung einer ‘demokratischen’, geschlossene Feedback-Loop Ethik → Recht → Ethik beschrieben
   - war aber gekennzeichnet durch große Wissens-, Ressourcen- und Macht-Asymmetrien zugunsten großer industrieller Stakeholder ←→ ethischer Diskurs
   - fördert vielmehr maximal eine spezifische Art von Ethik (z.B. die der Industrie: Chance der Selbstregulierung)
3. Das “speed paradigm” der Entwicklung der KI-VO mag ein zufriedenstellendes Gesetz geschaffen haben, läuft aber allen Regeln des ethischen Diskurses zuwider:
   - “AI is … a fast evolving and growing technology, … the chosen definition of AI … *makes an end run around it by being ‘future-proof’*, and … the definition allows a *swiftness of market compliance and adaptation* to the regulation which further facitlitates the development of AI as a fast-growing technology, thus closing the loop.”
   - Gefahr: “the bounds of our arena are now set; within that arena, as long as we follow these prohibitions to the letter, we are now free to do whatever we like without any further reflection upon the consequences.”

(Punkte 2 und 3: Anderson, 2022)

Zusammenfassung und Ausblick

Ethische Grundlagen in der KI-VO?
Beschreibung: Grundlagen; Folgen; Prinzipien und Regeln
Zweifel: Care
Kritik: Wissen

Bibliographie und Quellen

KI-VO: https://eur-lex.europa.eu/legal-content/DE/TXT/PDF/?uri=OJ:L_202401689

HLEG: https://op.europa.eu/en/publication-detail/-/publication/d3988569-0434-11ea-8c1f-01aa75ed71a1

Datenethikkommission: https://www.bmi.bund.de/SharedDocs/downloads/DE/publikationen/themen/it-digitalpolitik/gutachten-datenethikkommission.pdf

Anderson, M. (2022). Some ethical reflections on the EU AI Act. Proc. 1st International Workshop on Imagining the AI Landscape After the AI Act. CEUR-WS. https://ceur-ws.org/Vol-3221/IAIL_paper5.pdf

Ashurst, C., Hine, E., Sedille, P., & Carlier, A. (2022). AI Ethics Statements - Analysis and lessons learnt from NeurIPS Broader Impact Statements. In FAccT '22: Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency (pp. 2047 – 2056). ACM. https://doi.org/10.1145/3531146.3533780 , https://arxiv.org/abs/2111.01705

Berendt, B. (2022). The AI Act Proposal: Towards the next transparency fallacy? Why AI regulation should be based on principles based on how algorithmic discrimination works. In BMU & F. Rostalski (Eds.), Künstliche Intelligenz - Wie gelingt eine vertrauenswürdige Verwendung in Deutschland und Europa? Tübingen, Germany: Mohr Siebeck. (last author version)

Berendt, B. (2024). Consensual counterfeit people. To appear in K. Sachs-Hombach & M. Lemmes (Eds.), Die Zukunft der Bilder - Herausforderungen der Bildwissenschaft 2024. Herbert von Halem Verlag. (last author version)

D'Ignazio, Catherine and Klein, Lauren F., Data Feminism, Cambridge / MA 2020. https://data-feminism.mitpress.mit.edu/

Edwards, Lilian and Veale, Michael, Slave to the algorithm? Why a 'right to an explanation' is probably not the remedy you are looking for, Duke Law & Technology Review, 16 (1), 2017, 18-84. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2972855

Ensign, D., Friedler, S. A., Neville, S., Scheidegger, C., & Venkatasubramanian, S., Runaway Feedback Loops in Predictive Policing. Proceedings of Machine Learning Research 81, 2018, 160-171. https://proceedings.mlr.press/v81/ensign18a.html

Helberger, N., Naudts , L., & Piasecki, S. (Editors & Contributors); Contributors including Berendt, B. (2024). The Amsterdam Paper: Recommendations for the technical finalisation of the regulation of GPAI in the AI Act by the participants of the joint Media & Democracy Lab and Algorithm Watch legal design workshop. https://www.aim4dem.nl/the-amsterdam-paper-recommendations-for-the-technical-finalisation-of-the-regulation-of-gpai-in-the-ai-act/

Myrdal, Gunnar, An American Dilemma: The Negro Problem and Modern Democracy, New York 1944

Rehak, R. (2023). Zwischen Macht und Mythos. Eine kritische Einordnung aktueller KI-Narrative. Soziopolis: Gesellschaft beobachten. https://www.soziopolis.de/zwischen-macht-und-mythos.html

Ruschemeier, H. (2023). The Problem of the Automation Bias in the Public Sector: A Legal Perspective. In Proceedings of the Weizenbaum Conference 2023: AI, Big Data, Social Media, and People on the Move (pp. 1-11). Berlin: Weizenbaum Institute for the Networked Society - The German Internet Institute. https://doi.org/10.34669/wi.cp/5.6